Fashion Recommendation via Graph Neural Networks, Hybrid Collaborative Models and Web-Crawled Multimodal Data

Nguyen-Phuc Mac Qui-Hung Kieu Duy-Liem Nguyen Tri-Duc Tran

Faculty of Information Science and Engineering,
University of Information Technology - VNUHCM
{22521123,22520505,22520752,22520276}@gm.uit.edu.vn

Tóm tắt nội dung

Đồ án này giải quyết bài toán khuyến nghị thời trang dựa trên dữ liệu đa phương thức quy mô lớn thu thập từ Uniqlo Việt Nam. Thông qua việc đánh giá toàn diện các phương pháp từ truyền thống đến Mạng nơ-ron đồ thị (GNN) tiên tiến (LightGCN, NGCF, MMGCN, LightGCL), đồ án tập trung khai thác hiệu quả của học tương phản và dung hợp đặc trưng. Kết quả thực nghiệm khẳng định sự vượt trội của các kiến trúc đồ thị đa phương thức, đồng thời minh chứng vai trò then chốt của đặc trưng văn bản và embedding đa ngôn ngữ trong việc nâng cao độ chính xác gợi ý tại thị trường Việt Nam.

Từ khóa: Recommender Systems, Fashion Recommendation, Graph Neural Networks, Multimodal Learning.

1 Giới thiệu

Sự bùng nổ của thương mại điện tử, đặc biệt trong lĩnh vực thời trang, đã dẫn đến tình trạng quá tải thông tin, đặt ra thách thức lớn cho người tiêu dùng trong việc tìm kiếm và lựa chọn sản phẩm phù hợp. Trong bối cảnh đó, các hệ thống gợi ý (*Recommender Systems*) đóng vai trò then chốt trong việc cá nhân hóa trải nghiệm người dùng và hỗ trợ ra quyết định. Để giải quyết bài toán này, cộng đồng nghiên cứu đã phát triển đa dạng các hướng tiếp cận, từ các phương pháp nền tảng như *Lọc dựa trên nội dung* (*Content-Based Filtering*) khai thác thuộc tính sản phẩm, đến *Lọc cộng tác* (*Collaborative Filtering*) tận dụng các mẫu hình tương tác cộng đồng. Mỗi phương pháp đại diện cho một triết lý riêng biệt, tối ưu hóa dự đoán dựa trên đặc trưng dữ liệu hoặc trí tuệ đám đông.

Bên cạnh các phương pháp truyền thống, sự ra đời của Mạng nơ-ron đồ thị (*Graph Neural Networks – GNN*) và Học sâu đa phương thức (*Multimodal Deep Learning*) đã mở ra hướng đi mới trong việc mô hình hóa dữ liệu tương tác phức tạp. Các kiến trúc tiên tiến như NGCF, LightGCN, MMGCN và LightGCL cho phép biểu diễn cấu trúc liên kết người dùng – sản phẩm dưới dạng đồ thị, đồng thời dung hợp các nguồn thông tin đa dạng (hình ảnh, văn bản) để nâng cao độ chính xác. Trong đồ án này, chúng tôi thực hiện đánh giá thực nghiệm toàn diện trên tập dữ liệu thực tế từ Uniqlo, nhằm so sánh hiệu quả của các nhóm phương pháp từ truyền thống đến hiện đại. Mục tiêu là phân tích đặc điểm vận hành và xác định thế mạnh đặc thù của từng chiến lược trong bối cảnh gợi ý thời trang, qua đó cung cấp cơ sở tham chiếu cho việc lựa chọn mô hình phù hợp với các kịch bản ứng dụng thực tiễn.

2 Các công trình liên quan

Sự kết hợp giữa Mạng nơ-ron đồ thị (*Graph Neural Networks – GNN*) và Học sâu đa phương thức (*Multimodal Deep Learning*) đã tạo bước tiến lớn cho hệ thống gợi ý, đặc biệt trong lĩnh vực thời trang. Đồ án này kế thừa và phát triển dựa trên ba dòng chảy học thuật chính sau đây.

2.1 Lọc cộng tác dựa trên GNN

Việc mô hình hóa tương tác dưới dạng đồ thị lưỡng phân đã chứng minh hiệu quả vượt trội so với phân rã ma trận. Wang và cộng sự (2019) đề xuất *Neural Graph Collaborative Filtering* (NGCF), khai thác tính liên kết bậc cao (*high-order connectivity*) thông qua cơ chế truyền tin (*message passing*), tuy nhiên kiến trúc này đòi hỏi chi phí tính toán lớn. Để tối ưu hóa, He và cộng sự (2020) giới thiệu *LightGCN*, một mô hình cơ sở (*baseline*) hiệu quả giúp đơn giản hóa kiến trúc GCN bằng

cách loại bỏ các thành phần phi tuyến và chỉ giữ lại cơ chế tổng hợp lân cận (*neighborhood aggregation*) tuyến tính, tạo ra các biểu diễn mượt mà với độ phức tạp thấp hơn.

2.2 Gợi ý đa phương thức trong lĩnh vực thời trang

Đặc thù của thời trang đòi hỏi sự hiểu biết sâu sắc về thị giác và ngữ nghĩa. Trong khi *Multimodal Attention Network* (Chen và cộng sự, 2019) và *FashionBERT* (Gao và cộng sự, 2020) nhấn mạnh việc dung hợp dữ liệu đa nguồn (hình ảnh, văn bản), Wei và cộng sự (2019) đã nâng cấp hướng tiếp cận này dưới góc độ đồ thị với *Multi-modal Graph Convolution Network* (MMGCN). Thay vì nối đặc trưng đơn thuần, MMGCN xây dựng các đồ thị con riêng biệt cho từng phương thức, cho phép nắm bắt sở thích chi tiết của người dùng trên từng khía cạnh thị giác hoặc ngữ nghĩa, đặc biệt phù hợp với dữ liệu phức tạp.

2.3 Tăng cường độ bền vững với học tương phản

Nhằm giải quyết vấn đề thưa dữ liệu và nhiễu, Cai và cộng sự (2023) đề xuất *LightGCL*, tích hợp kỹ thuật học tương phản vào hệ thống gợi ý. Khác với các phương pháp tăng cường ngẫu nhiên dễ làm mất thông tin cấu trúc, LightGCL sử dụng Phân rã giá trị suy biến (*Singular Value Decomposition – SVD*) để tạo ra các góc nhìn tương phản toàn cục. Chiến lược này giúp tái cấu trúc đồ thị hiệu quả, hỗ trợ mô hình học được các biểu diễn bền vững và ổn định ngay cả trong điều kiện dữ liệu hạn chế.

3 Phương pháp thu thập và mô tả dữ liệu

3.1 Quy trình thu thập dữ liệu

Nhằm đảm bảo tính chính xác và đa dạng cho tập dữ liệu thực nghiệm, đồ án này xây dựng quy trình thu thập dữ liệu tự động từ website Uniqlo Việt Nam, kết hợp sử dụng Selenium để xử lý nội dung render động và BeautifulSoup4 cho tác vụ phân tích cú pháp HTML. Hệ thống được thiết kế theo cấu trúc phân cấp, duyệt tuần tự qua các danh mục sản phẩm chính và mô phỏng hành vi người dùng (cuộn trang, tải nội dung bất đồng bộ) thông qua WebDriverWait để đảm bảo tính ổn định trước các độ trễ mạng.

Quy trình trích xuất dữ liệu được thực hiện qua hai tầng: (1) *Tầng danh mục* thu thập thông tin cơ bản (tên, giá, liên kết sản phẩm); (2) *Tầng chi tiết* truy xuất sâu vào từng trang sản phẩm để lấy mô tả kỹ thuật, thành phần chất liệu, hình ảnh độ phân giải cao và lịch sử đánh giá của người dùng. Dữ liệu thô sau khi thu thập được xử lý ngoại lệ và chuẩn hóa định dạng nhằm loại bỏ nhiễu, đảm bảo tính nhất quán trước khi đưa vào giai đoạn tiền xử lý và huấn luyện mô hình.

3.2 Cấu trúc và mô tả bộ dữ liệu

Sau quá trình thu thập và tiền xử lý, bộ dữ liệu được tổ chức thành nhiều tệp riêng biệt nhằm phục vụ cho các mục tiêu phân tích và huấn luyện mô hình khác nhau. Thống kê định lượng tổng quan của bộ dữ liệu được trình bày trong Bảng 1.

3.2.1 Tệp thông tin sản phẩm

Tệp dữ liệu đóng vai trò là cơ sở dữ liệu tham chiếu (Master Data), lưu trữ các thuộc tính định danh và thông số kỹ thuật của sản phẩm. Danh sách thuộc tính chi tiết được trình bày tại Phụ lục B.

3.2.2 Tệp phản hồi khách hàng

Đây là nguồn dữ liệu chính phục vụ phân tích cảm xúc và dự báo hành vi. Trong bước tiền xử lý, các bản ghi thiếu định danh người dùng (Reviewer="NaN") bị loại bỏ hoàn toàn. Việc lọc bỏ các tài khoản ẩn danh thiếu lịch sử tương tác xác thực là bước thiết yếu để tránh gây nhiễu và đảm bảo độ chính xác cho các mô hình gợi ý cá nhân hóa. Cấu trúc dữ liệu sau làm sạch được mô tả tại Phụ lục B.

3.2.3 Phân tích đặc điểm dữ liệu qua trực quan hóa

Để hiểu rõ hơn về cấu trúc và phân bố của tập dữ liệu, nhóm đã tiến hành phân tích thống kê thông qua bốn biểu đồ trực quan trọng yếu, phản ánh các khía cạnh chính liên quan đến sản phẩm, khách hàng và chất lượng phản hồi.

Về đặc điểm sản phẩm và giá cả (Hình 1, 2), dữ liệu phản ánh rõ nét chiến lược tập trung vào các dòng sản phẩm thiết yếu của thương hiệu, với sự chiếm ưu thế của nhóm *Innerwear* và *T-shirts*. Phân phối giá cho thấy sự phân tầng rõ rệt: phần lớn sản phẩm

Dataset	Số lượng	Số thuộc tính	Mô tả
Product	352	13	Thông tin định danh, kỹ thuật và thương mại của sản phẩm.
Reviewer	4457	13	Thông tin đánh giá, bình luận và nhân trắc học của khách hàng.

Bảng 1: Thống kê định lượng bộ dữ liệu.

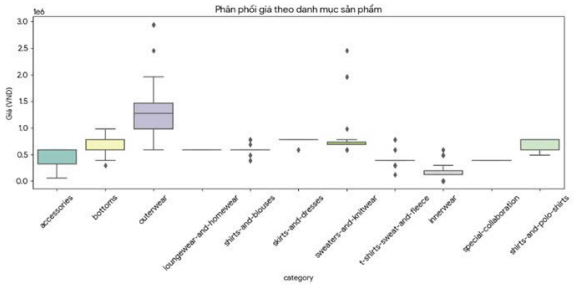

Hình 1: Phân phối giá theo danh mục sản phẩm.

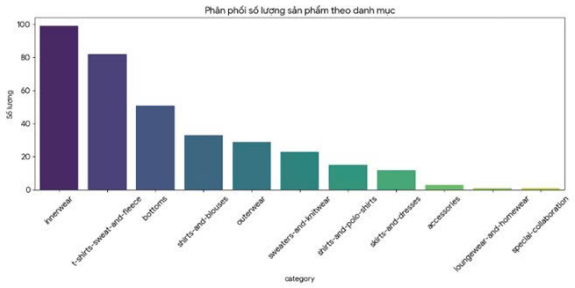

Hình 2: Phân phối số lượng sản phẩm theo danh mục.

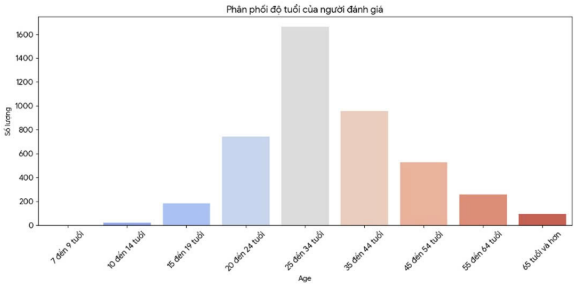

Hình 3: Phân phối độ tuổi của người đánh giá.

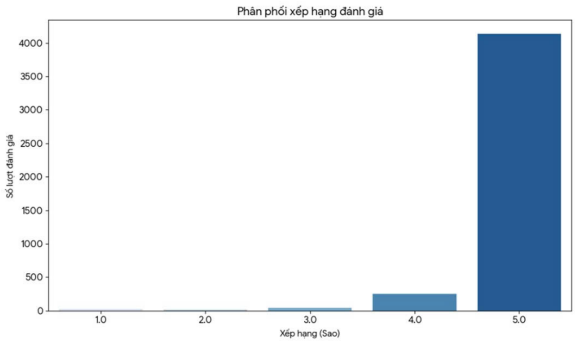

Hình 4: Phân phối xếp hạng đánh giá.

tập trung ở phân khúc dễ tiếp cận (160.000–400.000 VND), tách biệt hoàn toàn với nhóm *Outerwear* có mức giá trung bình cao nhất (trên 1,3 triệu VND).

Đối với đặc điểm khách hàng (Hình 3), phân bố nhân khẩu học cho thấy sự tập trung mạnh vào nhóm người dùng từ 25 đến 44 tuổi, chiếm hơn 60% tổng số lượt tương tác. Kết quả này xác nhận tệp khách hàng mục tiêu chủ yếu nằm trong độ tuổi lao động, cung cấp các tín hiệu hành vi quan trọng để định hình hồ sơ người dùng trong hệ thống gợi ý.

Về chất lượng phản hồi (Hình 4), dữ liệu thể hiện sự lệch chuẩn mạnh về phía tích cực, với tỷ lệ xếp hạng 5 sao chiếm áp đảo (trên 92%). Mặc dù phản ánh sự hài lòng cao về chất lượng sản phẩm, sự mất cân bằng dữ liệu (*data imbalance*) nghiêm trọng này đặt ra thách thức lớn trong việc kiểm soát thiên kiến (*bias*) khi huấn luyện các mô hình dự báo.

4 Phương pháp

4.1 Bài toán và kí hiệu

Bài toán được xem xét trong đồ án này là bài toán gợi ý Top-K trong hệ thống khuyến nghị, với dữ liệu đầu vào là tập tương tác ngầm (*implicit feedback*) giữa người dùng và sản phẩm. Gọi $U = \{u_1, u_2, \ldots, u_{|U|}\}$ là tập người dùng và $I = \{i_1, i_2, \ldots, i_{|I|}\}$ là tập sản phẩm. Tập tương tác $R = \{(u, i)\}$ biểu diễn việc người dùng $u \in U$ đã từng tương tác với sản phẩm $i \in I$.

Mục tiêu của mô hình là học một hàm chấm điểm $y_{ui} = f(u, i)$ sao cho, đối với mỗi người dùng u, các sản phẩm mà người dùng đã từng tương tác có điểm số cao hơn các sản phẩm chưa từng tương tác, từ đó cho phép xếp hạng và lựa chọn K sản phẩm có điểm số cao nhất để đưa ra khuyến nghị.

4.2 Xây dựng đồ thị tương tác

Từ dữ liệu tương tác, một đồ thị hai phía (*bipartite graph*) được xây dựng dưới dạng $G = (U \cup I, E)$, trong đó mỗi cạnh $(u, i) \in E$ biểu diễn một tương tác giữa người dùng $u \in U$ và sản phẩm $i \in I$. Đồ thị này cho phép mô hình hóa trực tiếp mối quan hệ người dùng–sản phẩm và đóng vai trò nền tảng cho quá trình lan truyền thông tin trong các mô hình khuyến nghị dựa trên đồ thị.

Trong quá trình lan truyền embedding, ma trận kề của đồ thị được chuẩn hóa đối xứng theo công thức:

$$\hat{A} = D^{-\frac{1}{2}} A D^{-\frac{1}{2}}, \tag{1}$$

trong đó A là ma trận kề của đồ thị và D là ma trận bậc. Cách chuẩn hóa này giúp đảm bảo sự ổn định về mặt số học trong quá trình huấn luyện, đồng thời hạn chế hiện tượng các nút có bậc lớn chi phối quá mức quá trình học biểu diễn.

4.3 Khởi tạo embedding

Mỗi người dùng và mỗi sản phẩm được biểu diễn bởi một vector embedding ban đầu trong không gian tiềm ẩn, lần lượt ký hiệu là $\mathbf{e}_u^{(0)}$ và $\mathbf{e}_i^{(0)}$, với $\mathbf{e}_u^{(0)}, \mathbf{e}_i^{(0)} \in \mathbb{R}^d$. Các embedding này được khởi tạo ngẫu nhiên và được cập nhật dần trong quá trình huấn luyện thông qua các cơ chế lan truyền thông tin trên đồ thị cũng như quá trình tối ưu hàm mất mát.

4.4 Content-Based Filtering

Phương pháp này khai thác các đặc trưng nội tại của sản phẩm thay vì dữ liệu tương tác, sử dụng embedding văn bản (*text embeddings*) và hình ảnh (*image embeddings*). Đặc trưng tổng hợp là sự kết hợp tuyến tính của hai phương thức thông tin này. Hồ sơ người dùng (*user profile*) được xây dựng bằng trung bình vector của các sản phẩm đã tương tác, và điểm gợi ý được tính qua độ tương đồng cosine. Phương pháp giải quyết hiệu quả bài toán *cold-start* cho sản phẩm mới, tuy nhiên bị hạn chế về khả năng khám phá (*exploration*).

4.5 User-Based Collaborative Filtering

Phương pháp này khai thác ma trận tương tác để tìm kiếm nhóm người dùng có hành vi tương đồng thông qua khoảng cách cosine. Hệ thống tính toán điểm gợi ý bằng cách tổng hợp có trọng số lịch sử tương tác của tập lân cận (k người dùng tương tự nhất). Cách tiếp cận này tận dụng hiệu quả trí tuệ đám đông (*wisdom of the crowd*) mà không cần đặc trưng sản phẩm, song gặp hạn chế về khả năng mở rộng quy mô và vấn đề *cold-start* đối với người dùng mới.

4.6 LightGCN

LightGCN được chọn làm mô hình cơ sở (*baseline*) nhờ kiến trúc tối giản, loại bỏ hoàn toàn các biến đổi phi tuyến và ma trận trọng số. Mô hình chỉ duy trì cơ chế lan truyền embedding tuyến tính trên đồ thị tương tác, với biểu diễn cuối cùng là trung bình của các tầng embedding. Thiết kế này giúp giảm thiểu đáng kể chi phí tính toán trong khi vẫn khai thác hiệu quả cấu trúc liên kết bậc cao giữa người dùng và sản phẩm.

4.7 LightGCL (Graph Contrastive Learning)

LightGCL cải tiến LightGCN bằng cách tích hợp học tương phản (*Graph Contrastive Learning*) để tăng cường độ bền vững của biểu diễn. Mô hình tạo ra các góc nhìn (*views*) khác nhau của đồ thị thông qua các biến đổi ngẫu nhiên như loại bỏ cạnh hoặc gây nhiễu embedding. Hàm mất mát tương phản được tối ưu hóa để kéo gần biểu diễn của cùng một nút trong các view khác nhau, giúp phân tách cấu trúc không gian tiềm ẩn rõ ràng hơn.

4.8 MMGCN

MMGCN (Multi-Modal Graph Convolutional Network) là phương pháp khuyến nghị tích hợp thông tin đa phương thức (văn bản, hình ảnh) vào cấu trúc đồ thị tương tác người dùng–sản phẩm nhằm học biểu diễn giàu ngữ nghĩa. Bằng cách lan truyền và hợp nhất đặc trưng đa phương thức trên đồ thị, MMGCN giúp cải thiện chất lượng biểu diễn nút và nâng cao độ chính xác của hệ thống gợi ý.

4.9 Hàm mất mát và huấn luyện

Các mô hình trong nghiên cứu được huấn luyện bằng hàm mất mát Bayesian Personalized Ranking (BPR), được định nghĩa như sau:

$$\mathcal{L}_{\text{BPR}} = -\sum_{(u,i,j)} \log \sigma\left(\hat{y}_{ui} - \hat{y}_{uj}\right), \tag{2}$$

trong đó (u, i, j) là một bộ gồm người dùng u, sản phẩm dương i và sản phẩm âm j được lấy mẫu, còn $\sigma(\cdot)$ là hàm sigmoid.

Đối với các mô hình có thành phần học tương phản, hàm mất mát tổng được xác định như sau:

$$\mathcal{L} = \mathcal{L}_{\text{BPR}} + \lambda \mathcal{L}_{\text{CL}} + \beta \|\Theta\|_2^2, \tag{3}$$

trong đó $\mathcal{L}_{\text{CL}}$ chỉ áp dụng cho LightGCL và các biến thể của nó, $\|\Theta\|_2^2$ là thành phần regularization nhằm hạn chế hiện tượng overfitting, còn λ và β là các hệ số điều chỉnh.

5 Kết quả thực nghiệm

Trước khi huấn luyện mô hình, chúng tôi tiến hành tiền xử lý nhằm chuẩn hóa định danh người dùng trong tập dữ liệu đánh giá. Do dữ liệu review không cung cấp user ID nhất quán, nhóm áp dụng cách tiếp cận dựa trên *cohort*, trong đó người dùng được biểu diễn như một nhóm cá thể có cùng đặc trưng nhân khẩu học.

Cụ thể, sáu thuộc tính gồm giới tính (*Gender*), độ tuổi (*Age*), chiều cao (*Height*), cân nặng (*Weight*), cỡ giày (*Shoe Size*) và quốc gia (*Country*) được kết hợp để tạo khóa nhóm. Các bản ghi có cùng tổ hợp thuộc tính được gộp thành một "người dùng" và gán một mã số nguyên, sử dụng như user ID trong quá trình xây dựng đồ thị và huấn luyện các mô hình gợi ý.

Cách tiếp cận này cho phép áp dụng các mô hình dựa trên đồ thị như LightGCN và LightGCL trong bối cảnh dữ liệu thưa. Tuy nhiên, mô hình học sở thích ở mức *nhóm nhân khẩu học* thay vì cá nhân, do đó các chỉ số Precision@K, Recall@K, NDCG@K và MRR@K phản ánh hiệu năng ở mức *segmentation-level*. Việc gom nhóm giúp tăng mật độ tương tác nhưng có thể làm suy giảm tín hiệu nếu các cohort không đủ phân biệt, cần được cân nhắc khi phân tích kết quả thực nghiệm.

5.1 Thiết lập thực nghiệm

Trong quá trình thực nghiệm, dữ liệu được chia thành các tập huấn luyện, xác thực và kiểm tra. Trong mỗi batch huấn luyện, *negative sampling* được áp dụng để xây dựng các cặp so sánh cho hàm mất mát Bayesian Personalized Ranking (BPR). Sau khi huấn luyện, các mô hình được đánh giá bằng các chỉ số Recall@K, Precision@K, NDCG@K và MRR@K, phản ánh cả khả năng bao phủ lẫn chất lượng thứ hạng của danh sách gợi ý. Khi đánh giá, các sản phẩm đã xuất hiện trong tập huấn luyện của mỗi người dùng được loại bỏ khỏi danh sách gợi ý nhằm đảm bảo tính công bằng và phù hợp với kịch bản sử dụng thực tế.

Chúng tôi tiến hành so sánh các mô hình gợi ý dựa trên đồ thị tương tác người dùng–sản phẩm, bao gồm LightGCN, NGCF, LightGCL và MMGCN. LightGCN được sử dụng làm mô hình baseline với cơ chế lan truyền embedding tuyến tính trên đồ thị. NGCF mở rộng bằng cách bổ sung các phép biến đổi phi tuyến và tổng hợp thông tin láng giềng phức tạp hơn. LightGCL khai thác học tương phản trên đồ thị (*Graph Contrastive Learning*) nhằm cải thiện khả năng khái quát hóa của embedding. MMGCN tích hợp embeddings đa phương thức để tăng hiệu quả khuyến nghị.

Tất cả các mô hình sử dụng BPR loss kết hợp *negative sampling*, với text embeddings được trích xuất bằng multilingual-MiniLM-L12-v2 và image embeddings bằng CLIP ViT-B/32. Việc đánh giá được thực hiện trên tập kiểm tra (*test set*) với cùng chiến lược loại bỏ các sản phẩm đã tương tác trong tập huấn luyện.

5.2 Kết quả thực nghiệm

Các thí nghiệm chúng tôi tiến hành bao gồm sử dụng các mô hình đồ thị kết hộp với việc sử dụng những mô hình truyền thống, đồng thời thử nghiệm xem similarity nào phù hợp với mô hình truyền thống và thử nghiệm các embeddings khác trên ảnh và trên text và so sánh sự hiệu quả giữa chúng.

5.2.1 So sánh sự hiệu quả giữa các mô hình khác nhau

Bảng 2 dưới đây trình bày kết quả đánh giá của các mô hình trên tập kiểm tra. Các chỉ số Recall@K, Precision@K, NDCG@K và MRR@K được báo cáo tương ứng với các giá trị K bằng 5, 10.

Bảng 2 kết quả cho thấy LightGCL và đặc biệt là MMGCN đạt hiệu năng nổi trội và ổn định nhất trên hầu hết các chỉ số đánh giá (Recall, Precision, NDCG và MRR) ở cả Top@5 và Top@10, phản ánh khả năng kết hợp hiệu quả giữa thông tin nội dung và cấu trúc đồ thị trong quá trình học biểu diễn. Ngược lại,

Model	R@5	P@5	N@5	M@5	R@10	P@10	N@10	M@10
Content-based	0.1053	0.0211	0.0680	0.0557	0.1531	0.0153	0.0834	0.0620
User-based	0.0622	0.0124	0.0465	0.0413	0.0718	0.0072	0.0495	0.0426
NGCF	0.0311	0.0062	0.0170	0.0125	0.0622	0.0062	0.0273	0.0169
LightGCN	0.0287	0.0057	0.0141	0.0095	0.0574	0.0057	0.0232	0.0131
MMGCN	**0.1172**	**0.0234**	**0.0795**	**0.0673**	**0.2057**	**0.0206**	**0.1090**	**0.0800**
LightGCL	**0.1172**	**0.0234**	0.0788	0.0662	**0.1531**	0.0153	0.0901	0.0707

Bảng 2: So sánh hiệu năng của các mô hình khác nhau theo các chỉ số Recall, Precision, NDCG và MRR. Đánh giá tại Top 5 và Top 10.

Model	Similarity	R@5	P@5	N@5	M@5
Content-based	Cosine	**0.1053**	**0.0211**	**0.0680**	**0.0557**
	Mahalanobis	0.0502	0.0100	0.0366	0.0321
	Dot	0.0933	0.0187	0.0613	0.0508
	Euclidean	0.0981	0.0196	0.0601	0.0477
User-based	Cosine	0.0622	0.0124	0.0465	0.0413
	Mahalanobis	0.0072	0.0014	0.0072	0.0072
	Dot	0.0574	0.0115	0.0415	0.0362
	Euclidean	0.0072	0.0014	0.0072	0.0072

Bảng 3: Phân tích so sánh các phép đo độ tương tự khác nhau lên hiệu năng của mô hình cơ sở (baseline).

các mô hình graph-based còn lại như NGCF và LightGCN chưa thể hiện được ưu thế rõ rệt, nhiều khả năng do cấu trúc đồ thị tương tác trong bài toán này chưa được mô hình hóa đầy đủ hoặc chưa đủ giàu thông tin để khai thác hiệu quả. Trong bối cảnh đó, phương pháp Content-based cho kết quả cạnh tranh hơn so với một số mô hình graph-based thuần túy, có thể được lý giải bởi việc đặc trưng nội dung trực tiếp phản ánh sở thích người dùng khi dữ liệu tương tác còn thưa hoặc cấu trúc đồ thị chưa được học tốt. Nhìn chung, kết quả thực nghiệm nhấn mạnh vai trò then chốt của LightGCL và MMGCN, đồng thời cho thấy lợi ích rõ ràng của việc tích hợp thông tin nội dung vào các mô hình dựa trên đồ thị trong các kịch bản mà graph-based chưa được tối ưu hóa đầy đủ.

5.2.2 So sánh sự hiệu quả giữa các độ đo tương đồng khác nhau với các mô hình baseline

Bảng 3 dưới đây trình bày kết quả đánh giá của các độ đo với các mô hình baseline. Với độ tương đồng Mahalanobis, sử dụng với PCA giảm về còn 128 chiều để phù hợp với tính chất của độ tương đồng này. Độ đo ở top 5 được trình bày ở bảng này, còn độ đo ở top 10 được trình bày thêm ở phần phụ lục A ở bảng 10.

Kết quả cho thấy, trong mô hình Content-based, độ đo Cosine đạt hiệu năng cao nhất trên tất cả các chỉ số đánh giá (R@5, P@5, N@5 và M@5), cho thấy sự phù hợp của Cosine similarity trong việc so sánh các biểu diễn đặc trưng nội dung có tính chất thưa và chuẩn hóa. Bên cạnh đó, các độ đo dựa trên khoảng cách như Euclidean và Dot product cho kết quả ở mức trung bình, trong khi Mahalanobis thể hiện hiệu năng kém hơn đáng kể, có thể do hạn chế trong việc ước lượng ma trận hiệp phương sai khi dữ liệu đặc trưng có chiều cao và số mẫu hữu hạn. Cuối cùng, đối với mô hình User-based, hiệu năng tổng thể thấp hơn so với Content-based trên hầu hết các độ đo tương đồng, phản ánh những khó khăn trong việc mô hình hóa sở thích người dùng chỉ dựa trên lịch sử tương tác, đặc biệt trong bối cảnh dữ liệu thưa.

5.2.3 So sánh sự hiệu quả giữa các mô hình text embeddings khác nhau

Bảng 4 trình bày kết quả đánh giá của các text embeddings với mô hình MMGCN và image embeddings CLIP ViT-B 32. Mô hình MMGCN được sử dụng vì hiệu năng vượt trội so với các mô hình còn lại. Độ đo ở top 5 được trình bày ở bảng này, còn độ đo ở top 10 được

Text Embeddings	R@5	P@5	N@5	M@5
multilingual-MiniLM-L12-v2	0.1268	0.0254	0.0822	0.0676
multilingual-mpnet-base-v2	0.1172	0.0234	0.0771	0.0640
stsb-xlm-r-multilingual	0.1316	**0.0263**	0.0907	**0.0772**
LaBSE	0.1890	0.0189	0.0964	0.0684
use-cmlm-multilingual	**0.2010**	0.0201	0.0987	0.0683
all-mpnet-base-v2	**0.2010**	0.0201	**0.0996**	0.0692

Bảng 4: So sánh hiệu năng của các mô hình text embeddings đa ngôn ngữ khác nhau đối với độ chính xác của hệ thống gợi ý.

Type	Img Embeddings	R@5	P@5	N@5	M@5
CLIP	CLIP_ViT_B_32	0.1172	0.0234	0.0795	0.0673
	CLIP_LAION_B16	**0.1292**	**0.0258**	0.0812	0.0656
	SigLIP_B16	**0.1292**	**0.0258**	**0.0836**	**0.0689**
	EVA02_CLIP_B16	0.0789	0.0158	0.0475	0.0374
Vision	Swin_Tiny	0.1244	0.0249	0.0773	0.0618
	CvT_13	0.0981	0.0196	0.0659	0.0553
	MaxViT_Tiny	0.1100	0.0220	0.0709	0.0581

Bảng 5: So sánh hiệu năng của các mô hình image embeddings khác nhau đối với độ chính xác của hệ thống gợi ý.

trình bày thêm ở phần phụ lục A ở bảng 11.

Nhìn chung, các mô hình dựa trên Sentence-BERT thể hiện ưu thế so với các phương pháp còn lại, trong đó stsb-xlm-r-multilingual đạt kết quả tốt nhất trên hầu hết các chỉ số (R@5, P@5, N@5 và M@5), cho thấy khả năng nắm bắt tốt mức độ tương đồng ngữ nghĩa giữa văn bản trong bối cảnh đa ngôn ngữ. Các mô hình all-mpnet-base-v2 và use-cmlm-multilingual cũng đạt hiệu năng cạnh tranh, đặc biệt ở các chỉ số Recall và NDCG, phản ánh chất lượng biểu diễn ngữ nghĩa giàu thông tin và ổn định. Ngược lại, các mô hình nhẹ hơn như multilingual-MiniLM-L12-v2 và multilingual-mpnet-base-v2 cho kết quả thấp hơn, trong khi LaBSE thể hiện hiệu năng trung bình, có thể do được tối ưu chủ yếu cho bài toán căn chỉnh ngôn ngữ hơn là đo lường tương đồng ngữ nghĩa chi tiết. Tổng thể, kết quả này nhấn mạnh vai trò quan trọng của việc lựa chọn mô hình embeddings phù hợp nhằm nâng cao độ chính xác của hệ thống gợi ý dựa trên nội dung văn bản đa ngôn ngữ.

5.2.4 So sánh sự hiệu quả giữa các mô hình image embeddings khác nhau

Bảng 5 trình bày kết quả đánh giá của các text embeddings với mô hình MMGCN và text embeddings multilingual-MiniLM-L12-v2. Độ đo ở top 5 được trình bày ở bảng này, còn độ đo ở top 10 được trình bày thêm ở phần phụ lục A ở bảng 12.

Nhóm mô hình dựa trên CLIP nhìn chung đạt kết quả vượt trội so với các mô hình thị giác thuần túy, trong đó CLIP_LAION_B_16 và SigLIP_B16 đạt hiệu năng cao nhất trên hầu hết các chỉ số đánh giá (R@5, P@5, N@5 và M@5), phản ánh khả năng học biểu diễn hình ảnh giàu ngữ nghĩa nhờ cơ chế tiền huấn luyện đa phương thức. Mô hình CLIP_ViT_B_32 cho kết quả thấp hơn đôi chút, trong khi EVA02_CLIP_B16 thể hiện hiệu năng kém hơn đáng kể, cho thấy sự khác biệt trong chiến lược tiền huấn luyện và khả năng chuyển giao sang bài toán khuyến nghị. Ngược lại, các mô hình Vision-only như Swin_Tiny, CvT_13 và MaxViT_Tiny đạt hiệu năng thấp hơn một cách nhất quán, cho thấy hạn chế của việc chỉ khai thác đặc trưng thị giác mà không có sự liên kết ngữ nghĩa với văn bản. Tổng thể, kết quả này khẳng định vai trò quan trọng của các mô hình image embeddings đa phương thức, đặc biệt là CLIP và SigLIP, trong việc nâng cao độ chính xác của hệ thống gợi ý dựa trên nội dung hình ảnh.

Model	Text ablation	R@5	P@5	N@5	M@5
Content-based	None	0.1053	0.0211	0.0680	0.0557
	- desc	0.1053	0.0211	0.0680	0.0557
	- mat	0.0933	0.0187	0.0640	0.0544
	- name	0.1053	0.0211	0.0680	0.0557
	- (mat+desc)	0.0933	0.0187	0.0640	0.0544
	- (name+mat)	0.0933	0.0187	0.0640	0.0544
	- (name+desc)	0.1053	0.0211	0.0680	0.0557
MMGCN	None	0.1172	0.0234	0.0795	0.0673
	- desc	**0.1220**	**0.0244**	**0.0823**	**0.0694**
	- mat	0.1100	0.0220	0.0694	0.0562
	- name	**0.1220**	**0.0244**	**0.0823**	**0.0694**
	- (mat+desc)	0.1100	0.0220	0.0694	0.0562
	- (name+mat)	0.1100	0.0220	0.0694	0.0562
	- (name+desc)	**0.1220**	**0.0244**	**0.0823**	**0.0694**
LightGCL	None	0.1172	0.0234	0.0788	0.0662
	- desc	0.1172	0.0234	0.0742	0.0602
	- mat	0.0957	0.0191	0.0697	0.0613
	- name	0.1172	0.0234	0.0742	0.0602
	- (mat+desc)	0.0957	0.0191	0.0697	0.0613
	- (name+mat)	0.0957	0.0191	0.0697	0.0613
	- (name+desc)	0.1172	0.0234	0.0742	0.0602

Bảng 6: Phân tích hiệu năng của thử nghiệm loại bỏ thành phần văn bản trên các mô hình gợi ý khác nhau.

5.3 Học loại bỏ

Ngoài việc thực nghiệm các embeddings khác nhau và các độ tương đồng khác nhau, chúng tôi còn tiến hành thực nghiệ loại bỏ một số thuộc tính và so sánh sự hiệu quả của các model sau khi thực nghiệm. Những model được sử dụng trong trường hợp này là content-based, MMGCN và LightGCL, vì chỉ những model này sử dụng những thuộc tính đa phương thức.

5.3.1 Loại bỏ trên text

Bảng 6 trình bày kết quả đánh giá dựa trên việc loại bỏ các thuộc tính text. 'desc' có nghĩa là mô tả, 'mat' là chất liệu và 'name' là tên sản phẩm. Độ đo ở top 5 được trình bày ở bảng này, còn độ đo ở top 10 được trình bày thêm ở phần phụ lục A ở bảng 8.

Đối với mô hình Content-based, việc loại bỏ các thành phần văn bản riêng lẻ (mô tả, chất liệu hoặc tên sản phẩm) hầu như không làm thay đổi đáng kể hiệu năng tổng thể, cho thấy mô hình này phụ thuộc tương đối đồng đều vào các đặc trưng nội dung và chưa tận dụng mạnh mẽ sự kết hợp giữa các nguồn thông tin văn bản. Ngược lại, với MMGCN, việc loại bỏ thành phần mô tả hoặc tên sản phẩm dẫn đến sự tăng nhẹ ở tất cả các chỉ số đánh giá, trong khi loại bỏ chất liệu gây ảnh hưởng giảm nhẹ hơn, cho thấy mô tả và tên đóng vai trò then chốt trong việc tăng cường biểu diễn đa phương thức của mô hình. Xu hướng tương tự cũng được quan sát ở LightGCL, nơi việc loại bỏ chất liệu hoặc các tổ hợp liên quan đến chất liệu làm giảm đáng kể hiệu năng, phản ánh mức độ nhạy cảm của mô hình đối với từng nguồn thông tin nội dung. Tổng thể, kết quả ablation chưa cho thấy sự thay đổi đáng kể giữa việc loại bỏ các đặc trưng text khác nhau.

5.3.2 Loại bỏ các modality

Bảng 7 trình bày kết quả đánh giá dựa trên việc loại bỏ các thuộc tính text. 'desc' có nghĩa là mô tả, 'mat' là chất liệu và 'name' là tên sản phẩm. Độ đo ở top 5 được trình bày ở bảng này, còn độ đo ở top 10 được trình bày thêm ở phần phụ lục A ở bảng 9.

Bảng kết quả so sánh hiệu năng của các mô hình trong thí nghiệm loại bỏ thành phần văn bản và hình ảnh, qua đó làm rõ mức độ đóng

Model	Ablation type	R@5	P@5	N@5	M@5
Content-based	Text	0.1053	0.0211	0.0673	0.0549
	Image	0.0646	0.0129	0.0393	0.0311
MMGCN	Text	**0.1124**	**0.0225**	**0.0732**	0.0604
	Image	0.0670	0.0134	0.0418	0.0336
LightGCL	Text	0.0981	0.0196	0.0731	**0.0650**
	Image	0.0263	0.0053	0.0162	0.0128

Bảng 7: Phân tích so sánh hiệu năng giữa thử nghiệm loại bỏ thành phần văn bản và thành phần hình ảnh.

góp của từng loại thông tin vào chất lượng khuyến nghị. Nhìn chung, việc loại bỏ thành phần hình ảnh dẫn đến sự suy giảm hiệu năng rõ rệt hơn so với loại bỏ thành phần văn bản ở cả ba mô hình, đặc biệt thể hiện qua các chỉ số Recall và NDCG, cho thấy vai trò quan trọng của thông tin thị giác trong việc mô hình hóa sở thích người dùng. Đối với MMGCN, mô hình vẫn duy trì hiệu năng tương đối cao khi chỉ sử dụng văn bản, trong khi hiệu năng giảm mạnh khi chỉ sử dụng hình ảnh, phản ánh khả năng khai thác thông tin ngôn ngữ hiệu quả hơn trong kiến trúc đa phương thức. Xu hướng tương tự được quan sát ở LightGCL, nơi việc loại bỏ văn bản làm suy giảm đáng kể hiệu năng so với trường hợp loại bỏ hình ảnh, cho thấy sự phụ thuộc lớn của mô hình vào đặc trưng văn bản. Tổng thể, kết quả nhấn mạnh rằng sự kết hợp giữa văn bản và hình ảnh là cần thiết để đạt hiệu năng tối ưu, đồng thời khẳng định vai trò trung tâm của thông tin văn bản trong các mô hình graph-based tích hợp nội dung như MMGCN và LightGCL.

6 Hướng phát triển tương lai

Mặc dù đạt được các kết quả tích cực, nghiên cứu vẫn tồn tại một số hạn chế. Dữ liệu sử dụng chưa thuần Việt, do mô tả sản phẩm và tên công nghệ vải thường pha trộn giữa tiếng Việt và tiếng Anh, gây khó khăn cho các mô hình ngôn ngữ đơn ngữ. Hơn nữa, tập dữ liệu sản phẩm chưa bao phủ đầy đủ các loại trang phục mang tính đặc thù văn hóa Việt Nam như áo dài, dẫn đến giới hạn về khả năng khái quát trong các bối cảnh ứng dụng rộng hơn. Ngoài ra, quy mô dữ liệu tương tác còn tương đối nhỏ và thưa, làm giảm hiệu quả của các phương pháp lọc cộng tác thuần túy.

Trong tương lai, đồ án có thể phát triển bằng việc khai thác các mô hình embedding đa phương thức tiên tiến hơn cũng như các mô hình ngôn ngữ lớn (LLMs) để tăng cường khả năng hiểu ngữ nghĩa sâu và sinh lời giải thích cho khuyến nghị. Ngoài ra, việc xây dựng user ID dựa trên lịch sử tương tác thực tế của từng cá nhân thay vì cohort sẽ giúp hệ thống tiến gần hơn đến cá nhân hóa hoàn chỉnh. Cuối cùng, việc triển khai hệ thống dưới dạng ứng dụng thời gian thực và đánh giá thông qua phản hồi trực tiếp từ người dùng sẽ là bước quan trọng để kiểm chứng hiệu quả trong môi trường thực tế.

7 Kết luận

Trong đồ án này, chúng tôi đã xây dựng và đánh giá một hệ thống khuyến nghị thời trang dựa trên dữ liệu thực tế thu thập từ Uniqlo Việt Nam, bao gồm cả thông tin nội dung sản phẩm và hành vi người dùng. Thông qua việc triển khai và so sánh đồng thời nhiều nhóm phương pháp khác nhau, đồ án đã cung cấp một cái nhìn toàn diện về hiệu quả và đặc điểm của từng hướng tiếp cận trong bối cảnh dữ liệu thời trang. Kết quả thực nghiệm cho thấy các mô hình đa phương thức dựa trên đồ thị, đặc biệt là MMGCN và LightGCL, đạt hiệu năng vượt trội trên hầu hết các chỉ số đánh giá. Việc tích hợp thông tin văn bản và hình ảnh giúp mô hình nắm bắt tốt hơn đặc trưng sản phẩm cũng như sở thích người dùng, trong đó đặc trưng văn bản đóng vai trò quan trọng nhất do mang tính định danh cao đối với các sản phẩm thời trang cơ bản. Bên cạnh đó, cơ chế học tương phản trên đồ thị giúp cải thiện khả năng khái quát hóa và tăng độ ổn định của embedding trong điều kiện dữ liệu tương tác còn hạn chế.

References

Xuheng Cai, Chao Huang, Lianghao Xia, and Xubin Ren. 2023. Lightgcl: Simple yet effective graph contrastive learning for recommendation. *Preprint*, arXiv:2302.08191.

Xu Chen, Hanxiong Chen, Hongteng Xu, Yongfeng Zhang, Yixin Cao, Zheng Qin, and Hongyuan Zha. 2019. Personalized fashion recommendation with visual explanations based on multimodal attention network: Towards visually explainable recommendation. In *Proceedings of the 42nd international ACM SIGIR conference on research and development in information retrieval*, pages 765–774.

Dehong Gao, Linbo Jin, Ben Chen, Minghui Qiu, Peng Li, Yi Wei, Yi Hu, and Hao Wang. 2020. Fashionbert: Text and image matching with adaptive loss for cross-modal retrieval. In *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 2251–2260.

Xiangnan He, Kuan Deng, Xiang Wang, Yan Li, Yongdong Zhang, and Meng Wang. 2020. Lightgcn: Simplifying and powering graph convolution network for recommendation. In *Proceedings of the 43rd International ACM SIGIR conference on research and development in Information Retrieval*, pages 639–648.

Xiang Wang, Xiangnan He, Meng Wang, Fuli Feng, and Tat-Seng Chua. 2019. Neural graph collaborative filtering. In *Proceedings of the 42nd international ACM SIGIR conference on Research and development in Information Retrieval*, pages 165–174.

Yinwei Wei, Xiang Wang, Liqiang Nie, Xiangnan He, Richang Hong, and Tat-Seng Chua. 2019. Mmgcn: Multi-modal graph convolution network for personalized recommendation of micro-video. In *Proceedings of the 27th ACM international conference on multimedia*, pages 1437–1445.

A Phụ lục A: Các bảng với độ đo @10

Do giới hạn về kích thước trang nên các độ đo @10 sẽ được note ở phần này.

B Phụ lục B: Mô tả các thuộc tính trong 2 bộ dataset

Phần này bao gồm 2 bảng mô tả các thuộc tính trong 2 dataset được sử dụng trong bài.

Model	Text ablation	R@10	P@10	N@10	M@10
Content-based	None	0.1531	0.0153	0.0834	0.0620
	- desc	0.1531	0.0153	0.0834	0.0620
	- mat	0.1603	0.0160	0.0858	0.0634
	- name	0.1531	0.0153	0.0834	0.0620
	- (mat+desc)	0.1603	0.0160	0.0858	0.0634
	- (name+mat)	0.1603	0.0160	0.0858	0.0634
	- (name+desc)	0.1531	0.0153	0.0834	0.0620
MMGCN	None	**0.2057**	**0.0206**	0.1090	0.0800
	- desc	**0.2057**	**0.0206**	**0.1092**	**0.0804**
	- mat	0.2010	0.0201	0.0983	0.0679
	- name	0.2057	**0.0206**	**0.1092**	**0.0804**
	- (mat+desc)	0.2010	0.0201	0.0983	0.0679
	- (name+mat)	0.2010	0.0201	0.0983	0.0679
	- (name+desc) **0.2057**	**0.0206**	**0.1092**	**0.0804**	
LightGCL	None	0.1531	0.0153	0.0901	0.0707
	- desc	0.1699	0.0170	0.0908	0.0668
	- mat	0.1483	0.0148	0.0862	0.0678
	- name	0.1699	0.0170	0.0908	0.0668
	- (mat+desc)	0.1483	0.0148	0.0862	0.0678
	- (name+mat)	0.1483	0.0148	0.0862	0.0678
	- (name+desc)	0.1699	0.0170	0.0908	0.0668

Bảng 8: Phân tích hiệu năng của thử nghiệm loại bỏ thành phần văn bản trên các mô hình gợi ý khác nhau ở độ đo @10, bổ sung cho bảng 6.

Model	Ablation type	R@10	P@10	N@10	M@10
Content-based	Text	0.1651	0.0165	0.0862	0.0624
	Image	0.1244	0.0124	0.0590	0.0394
MMGCN	Text	**0.2010**	**0.0201**	**0.1017**	**0.0721**
	Image	0.1340	0.0134	0.0636	0.0427
LightGCL	Text	0.1435	0.0144	0.0876	0.0709
	Image	0.0526	0.0053	0.0246	0.0162

Bảng 9: Phân tích so sánh hiệu năng giữa thử nghiệm loại bỏ thành phần văn bản và thành phần hình ảnh ở độ đo @10, bổ sung cho bảng 7.

Model	Similarity	R@10	P@10	N@10	M@10
Content-based	Cosine	0.1531	0.0153	**0.0834**	**0.0620**
	Mahalanobis	0.0718	0.0072	0.0436	0.0349
	Dot	0.1603	0.0160	0.0827	0.0595
	Euclidean	**0.1722**	**0.0172**	0.0832	0.0568
User-based	Cosine	0.0718	0.0072	0.0495	0.0426
	Mahalanobis	0.0144	0.0014	0.0093	0.0080
	Dot	0.0574	0.0079	0.0483	0.0390
	Euclidean	0.0144	0.0014	0.0093	0.0080

Bảng 10: Phân tích so sánh các phép đo độ tương tự khác nhau lên hiệu năng của mô hình cơ sở (baseline) ở độ đo @10, bổ sung cho bảng 3.

Text Embeddings	R@10	P@10	N@10	M@10
multilingual-MiniLM-L12-v2	0.2057	0.0206	0.1076	0.0780
multilingual-mpnet-base-v2	**0.2081**	**0.0208**	0.1065	0.0761
stsb-xlm-r-multilingual	0.2057	0.0206	**0.1145**	**0.0870**
LaBSE	0.1890	0.0189	0.0964	0.0684
use-cmlm-multilingual	0.2010	0.0201	0.0987	0.0683
all-mpnet-base-v2	0.2010	0.0201	0.0996	0.0692

Bảng 11: So sánh hiệu năng của các mô hình text embeddings đa ngôn ngữ khác nhau đối với độ chính xác của hệ thống gợi ý ở độ đo @10, bổ sung cho bảng 4.

Type	Img Embeddings	R@10	P@10	N@10	M@10
CLIP	CLIP_ViT_B_32	0.2057	0.0206	0.1090	0.0800
	CLIP_LAION_B16	**0.2129**	**0.0213**	**0.1087**	0.0772
	SigLIP_B16	0.2081	0.0208	0.1085	**0.0788**
	EVA02_CLIP_B16	0.1268	0.0127	0.0632	0.0440
Vision	Swin_Tiny	0.1914	0.0191	0.0984	0.0702
	CvT_13	0.1603	0.0160	0.0861	0.0637
	MaxViT_Tiny	0.1651	0.0165	0.0884	0.0652

Bảng 12: So sánh hiệu năng của các mô hình image embeddings khác nhau đối với độ chính xác của hệ thống gợi ý ở độ đo @10, bổ sung cho bảng 5.

Thuộc tính	Mô tả
category	Danh mục phân loại sản phẩm (ví dụ: accessories, innerwear, outerwear,. . .).
product_url	Đường dẫn URL đến trang chi tiết sản phẩm trên website.
product_name	Tên thương mại đầy đủ của sản phẩm.
gender	Giới tính mục tiêu của sản phẩm (Nam/Nữ/Unisex).
size	Các biến thể kích cỡ của sản phẩm (One Size, S, M, L...).
price	Giá bán hiện tại (VND).
rate	Điểm đánh giá trung bình của sản phẩm (thang 5.0).
number_of_rates	Tổng số lượng lượt đánh giá tích lũy.
description	Mô tả ngắn gọn về sản phẩm (thường bao gồm tên và mã SKU hiển thị).
material	Thông tin chi tiết về thành phần vải và tỷ lệ các chất liệu.
washing_inst	Các hướng dẫn về bảo quản, giặt ủi từ nhà sản xuất.
product_code	Mã định danh duy nhất (ID) của sản phẩm.
img_url	Đường dẫn đến hình ảnh đại diện chất lượng cao của sản phẩm.

Bảng 13: Các thuộc tính trong bộ dữ liệu sản phẩm.

Thuộc tính	**Mô tả**
product_url	Đường dẫn đến sản phẩm được đánh giá (dùng để liên kết với bảng Sản phẩm).
product_name	Tên của sản phẩm tại thời điểm đánh giá.
product_code	Mã định danh sản phẩm (khóa ngoại liên kết).
reviewer	Tên hiển thị của khách hàng (đã lọc bỏ các giá trị vô danh ").
rating	Điểm số khách hàng chấm cho sản phẩm (ví dụ: "5 out of 5 stars").
comment	Nội dung văn bản bình luận chi tiết về trải nghiệm sản phẩm.
review_date	Ngày tháng khách hàng thực hiện đánh giá.
gender	Giới tính của người đánh giá.
age	Nhóm độ tuổi của khách hàng (ví dụ: 25 đến 34 tuổi).
height	Khoảng chiều cao của khách hàng (ví dụ: 156 - 160cm).
weight	Khoảng cân nặng của khách hàng (ví dụ: 51 - 55kg).
shoe_size	Kích cỡ giày của khách hàng (nếu có).
country	Quốc gia nơi khách hàng sinh sống hoặc thực hiện mua hàng.

Bảng 14: Các thuộc tính trong bộ dữ liệu phản hồi khách hàng.